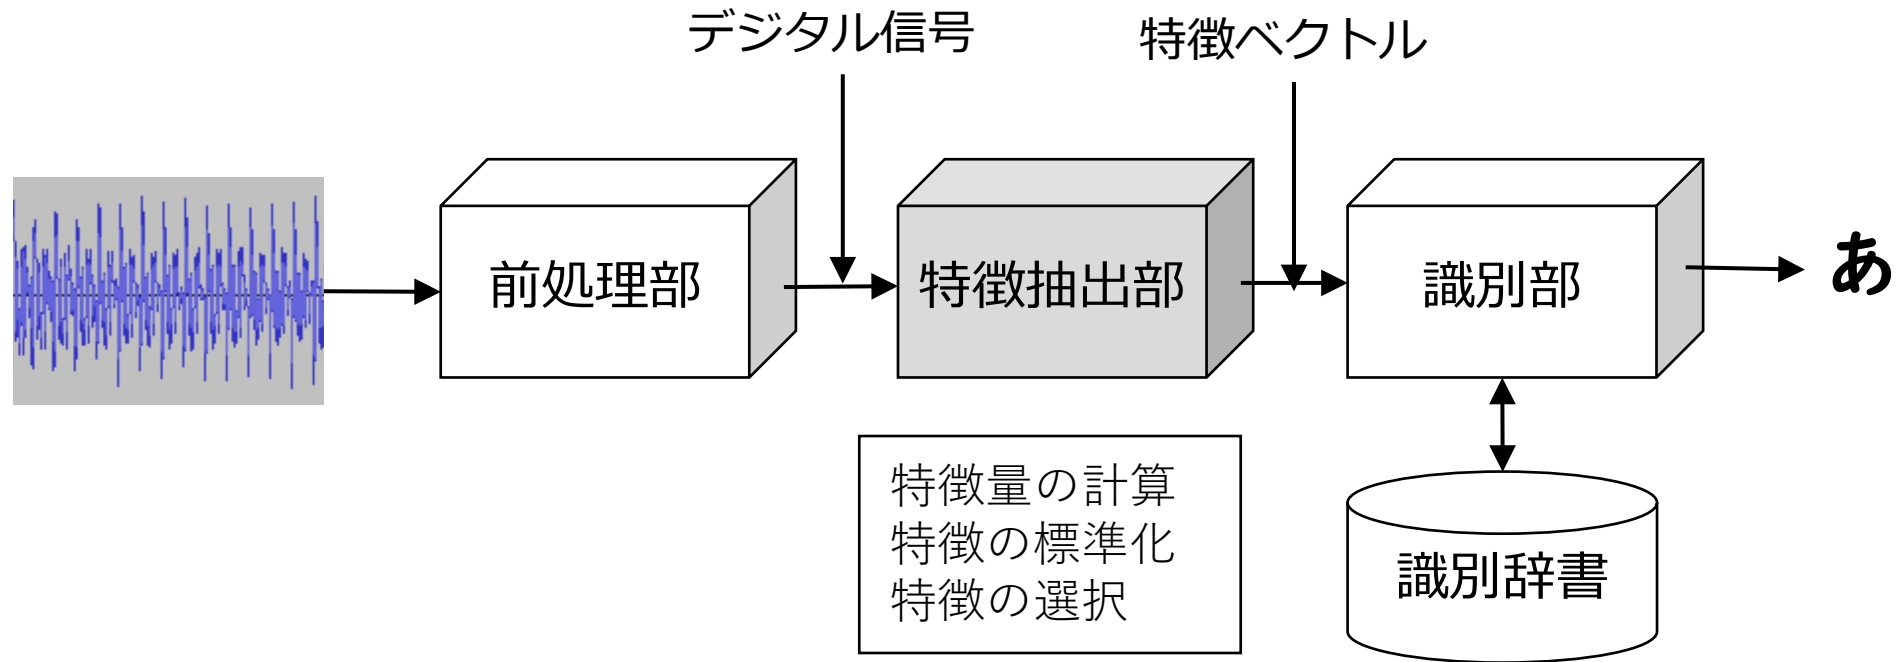



3. パターンの特徴を調べよう



3.1 変動に強い特徴とは


3.1.1 音声の場合

- 音素の違いとは
 - ◆ 声帯を振動の有無
(パルス波か雑音か)
 - ◆ 声道(口の開き具合・舌の位置など)の変形
→ 共振周波数の違いが大きな特徴



(a) 発声と調音の仕組み

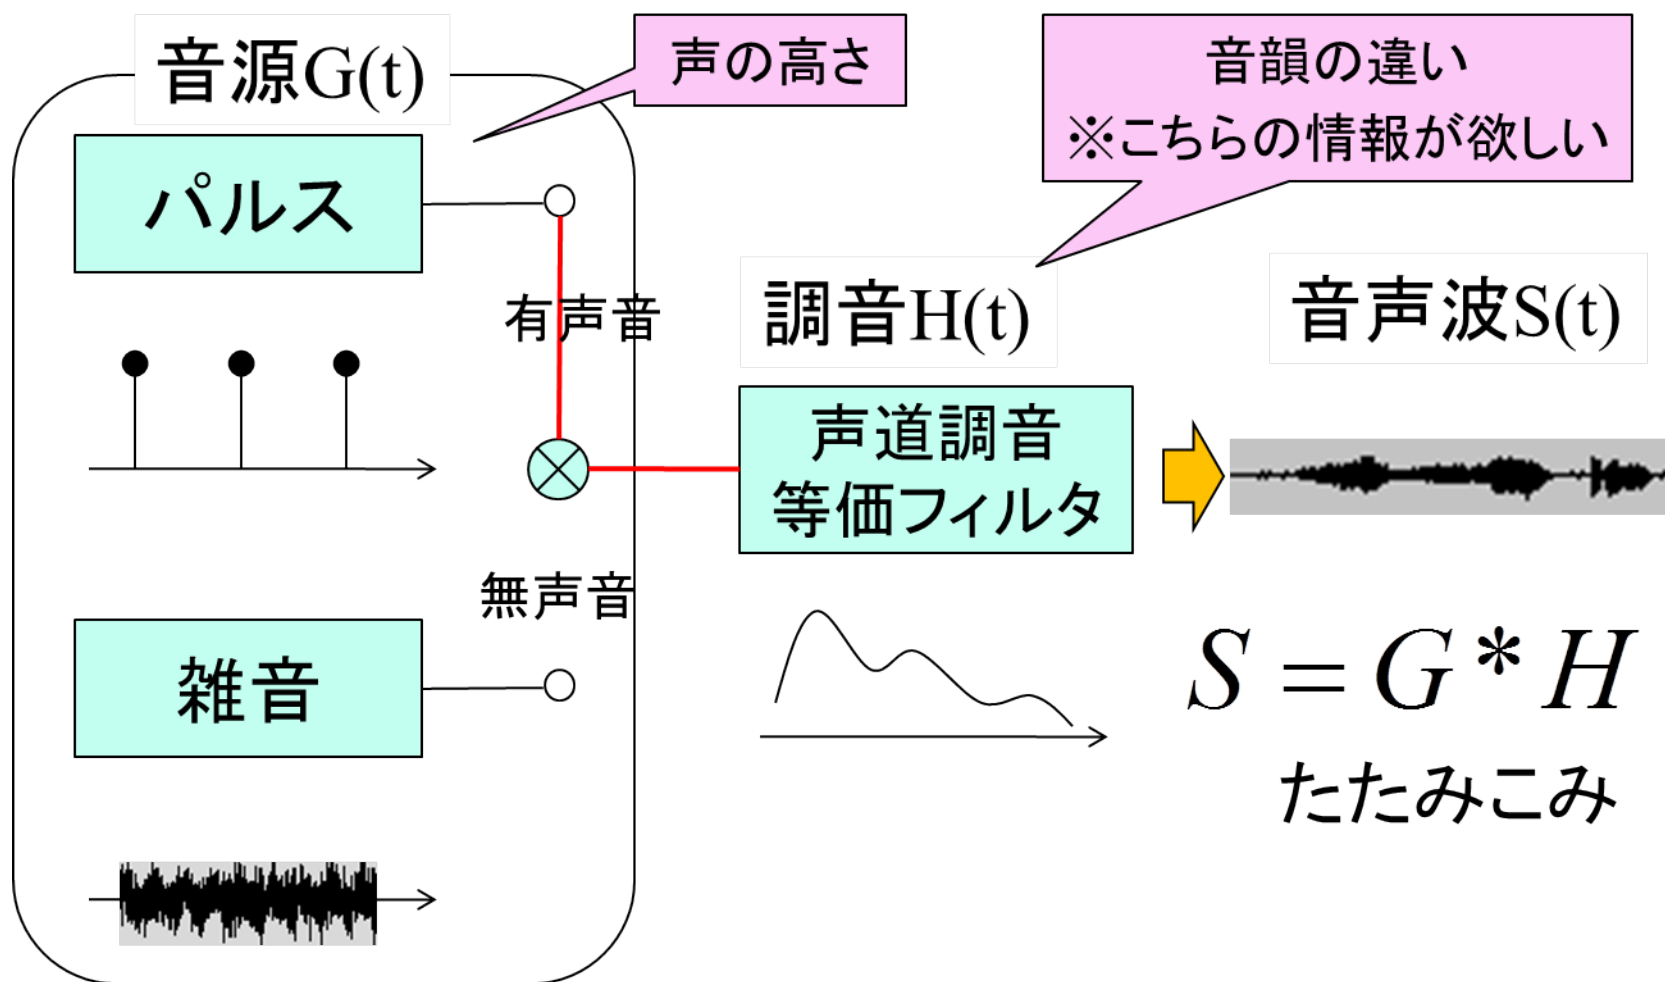
3.1.1 音声の場合



(b) 日本語母音識別のための特徴空間（男性） 軸の単位はHz

3.1.1 音声の場合


- 音声生成過程のモデル



3.1.1 音声の場合

- 調音フィルタ特性の取り出し

音声信号 $S = G * H$




フーリエ変換

スペクトル $S = G \cdot H$



絶対値・メルフィルタ・対数化

$$\log|S| = \log|G| + \log|H|$$



離散コサイン変換

ケプストラム $DCT \log|S| = DCT \log|G| + DCT \log|H|$

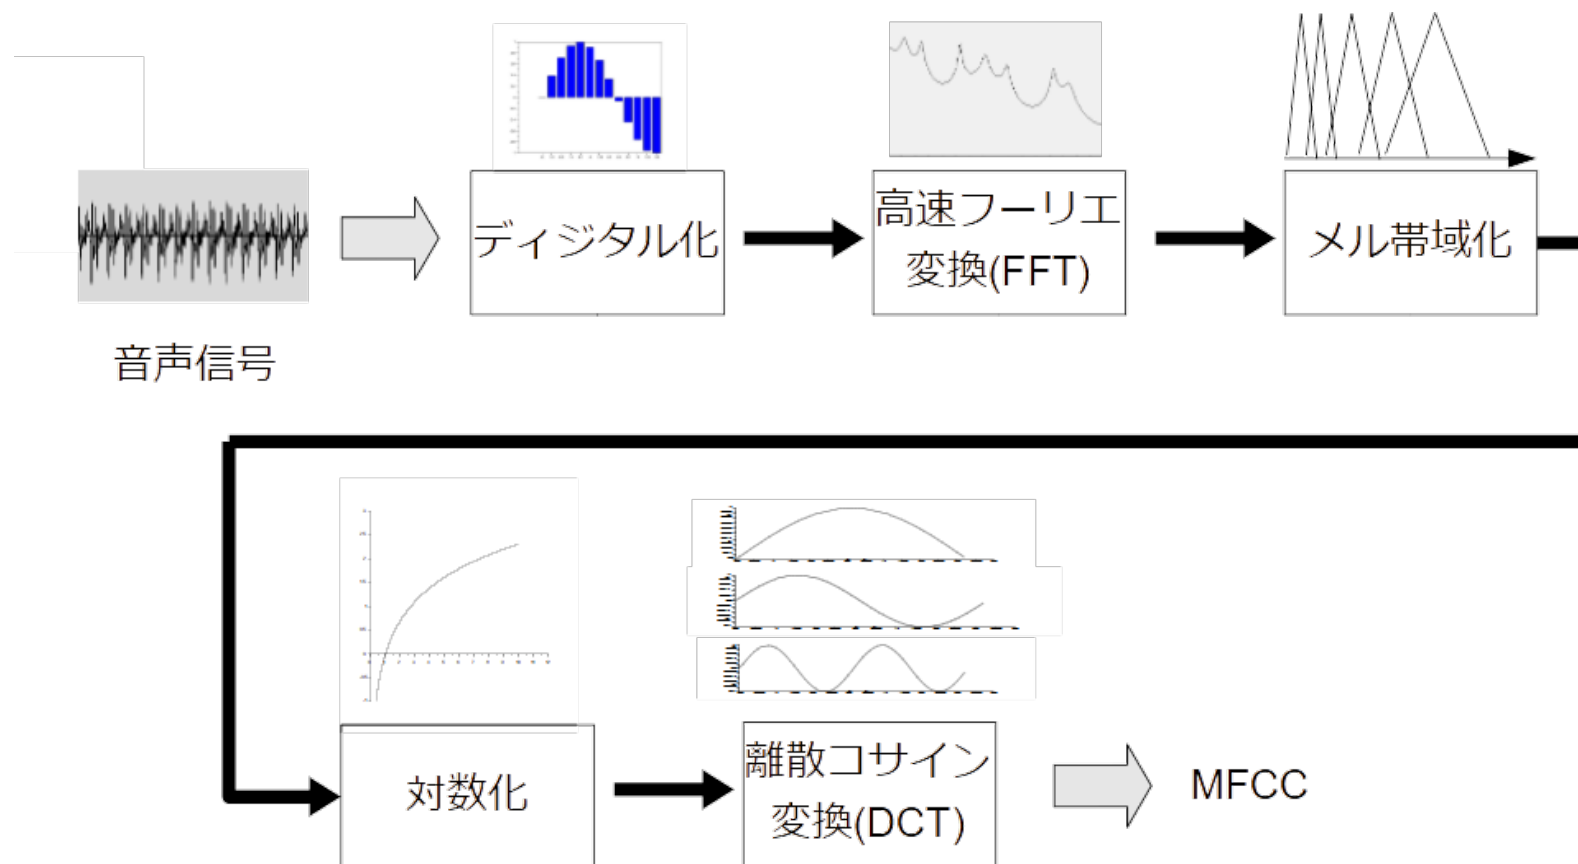
人間の感覚上の
音の高さを反映
(高周波ほど鈍感)

ケプストラム
※音のスペクトルを
信号と見なしてフー
リエ変換したもの

3.1.1 音声の場合


- MFCC (Mel Frequency Cepstrum Coefficient)

- ◆ スペクトルの概形情報を抽出



3.1.2 画像の場合


- 画像の変動
 - ◆ 明るさの変化, 拡大・縮小, 回転など
- SIFT特徴量
 - ◆ 2枚の画像の対応抽出などに有効



3.1.2 画像の場合

- Bag of Visual Words

- ◆ SIFT特徴量の似ているベクトルを単語と見なし、その出現頻度を特徴として識別問題に適用



自然言語処理の場合

- Bag of Words

- ◆ 応用：文書分類

- 例) 商品レビューを 肯定的/否定的 に分類する

- ◆ 文書を単語の多重集合(bag)とみなす

- 文例) 「顔認証はヤバいぐらい便利」

形態素解析「顔認証 は ヤバい ぐらい 便利」



単語の種類数 = 次元数

(0, ..., 0, 1, 0, ..., 1, 0, 1, ...)

顔認証



ヤバい 便利

Positive

分類ラベル

3.2 特徴のスケールを揃える

- 各軸で値のスケールが異なる場合
 - ◆ 値の標準化が必要



3.2 特徴のスケールを揃える

- スケールの揃え方
 - ◆ 特徴空間の単位超立方体の体積を軸伸縮の前後で一定に保ち、かつパターン相互の距離を最小化
→ 各軸の分散を等しくする
- 平均値を0にしておく
 - ◆ 学習における初期値の調整が不要
- 標準化の式

$$x'_i = \frac{x_i - m_i}{\sigma_i}$$

m_i, σ_i : 軸 i の平均、標準偏差

3.3 特徴は多いほどよいか

3.3.1 偶然に見つかってはまずい

(1) 偶然の傾向とは

- 特徴は多いほどよいか
 - ◆ 特徴が多くデータ数が少ないと、偶然の傾向が現れるかもしれない
 - ◆ 特徴の次元数が高いほど、偶然の傾向が発見される可能性が高い

3.3.1 偶然に見つかってはまずい

(2) 学習に必要なパターン数

- 超平面の容量 $2(d+1)$

- ◆ $p(n, d)$: d 次元空間上で、適当に配置された n 個のパターンを任意に2クラスに分けたとき、超平面により線形分離できる確率

$$n < 2(d + 1) : p(n, d) \sim 1$$

$$n = 2(d + 1) : p(n, d) = 1/2$$

$$n > 2(d + 1) : p(n, d) \sim 0$$

3.3.1 偶然に見つかってしまっはまずい

- 例題3.3

- ◆ データ数: 4

- ◆ 次元数: 1

$$p(4, 1) = 1/2$$

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(a) データの配置

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(b) 二つに分離可能

3.3.1 偶然に見つかってしまっはまずい



(3) 見つかるはずのないものが見つかった？

- $n \gg 2(d+1)$ のとき
 - ◆ もし、この条件で識別面が見つかったとしたら
 - 偶然には存在しえないものが見つかった
 - その識別面は必然的に存在していた

3.2.2 特徴を減らそう

(1) 力業で次元を減らす → 全ての組み合わせを評価する

(2) スマートに主成分分析



共分散行列とは

- データの広がりを知る→共分散行列

- 1次元の場合

- ◆ 平均

$$m = \frac{1}{N} \sum_{x \in \chi} x$$

- ◆ 分散

$$\sigma^2 = \frac{1}{N} \sum_{x \in \chi} (x - m)^2$$

- 多次元の場合

- ◆ 平均ベクトル



$$\mathbf{m} = \frac{1}{N} \sum_{\mathbf{x} \in \chi} \mathbf{x}$$

- ◆ 共分散行列

$$\Sigma = \frac{1}{N} \sum_{\mathbf{x} \in \chi} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T$$

共分散行列とは

- 各軸の平均・分散が等しいデータを区別できる



$$\Sigma = \begin{pmatrix} x\text{の分散} & x\text{と}y\text{の相関} \\ x\text{と}y\text{の相関} & y\text{の分散} \end{pmatrix}$$

3.2.2 特徴を減らそう

- 主成分分析

- ◆ 共分散行列からデータが広がっている方向（大きな固有値に対応する固有ベクトルの方向）を求める
- ◆ そのうちのいくつかのベクトルで変換行列を構成し、高次元データを低次元データに変換する

3.2.2 特徴を減らそう

- 変換行列

- ◆ 変換前の特徴空間におけるパターンの共分散行列 Σ の上位 \tilde{d} 個の固有値に対応する固有ベクトルを列とする行列

$$A = \begin{pmatrix} a_{11} & \dots & a_{1\tilde{d}} \\ \vdots & \ddots & \vdots \\ a_{d1} & \dots & a_{d\tilde{d}} \end{pmatrix}$$

- 次元数の削減 $Y = XA$

第3章 まとめ

- 特徴抽出部の役割
 - ◆ 特徴量の計算
 - 入力の種類および認識対象によって処理が異なる
 - ◆ 特徴の標準化
 - スケールの異なる特徴の識別に対する効果を公平にする
 - ◆ 特徴の選択
 - 実験的に有効な特徴を調べる
 - 低次元に変換する