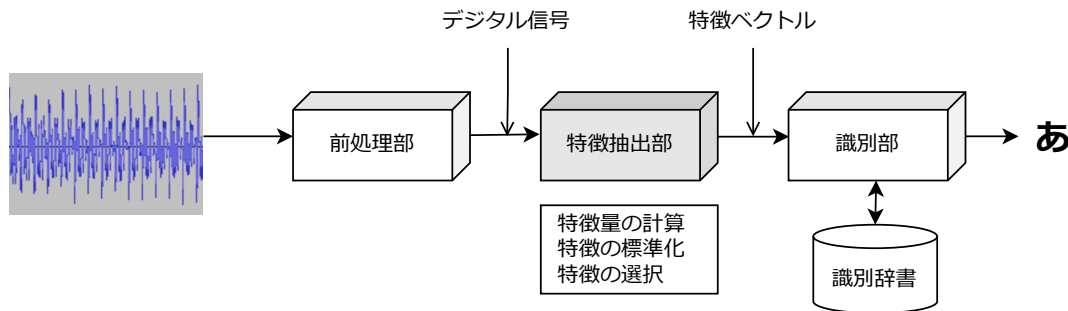



3. パターンの特徴を調べよう



- 3.1 変動に強い特徴とは
- 3.2 特徴のスケールを揃える
- 3.3 特徴は多いほどよいか




- 荒木雅弘:『フリーソフトでつくる
音声認識システム(第2版)』(森北
出版, 2017年)
- [スライドとJupyter notebook](#)
- [サポートページ](#)

3.1 変動に強い特徴とは

3.1.1 音声の場合 (1/6)


- 音素の違いとは
 - 声帯振動の有無(パルス波 / 雑音)
 - 母音:声道(口の開き具合・舌の位置など)の変形による共振周波数の違い
 - 子音:声道や口唇の変化パターンの違い



(a) 発声と調音の仕組み


3.1.1 音声の場合 (2/6)

- 音声のスペクトル
 - 音声波形中の一定時間を切り出し、フーリエ変換によって周波数成分に分解したもの
 - 音編集ソフト Audacity で表示したスペクトル



3.1.1 音声の場合 (3/6)

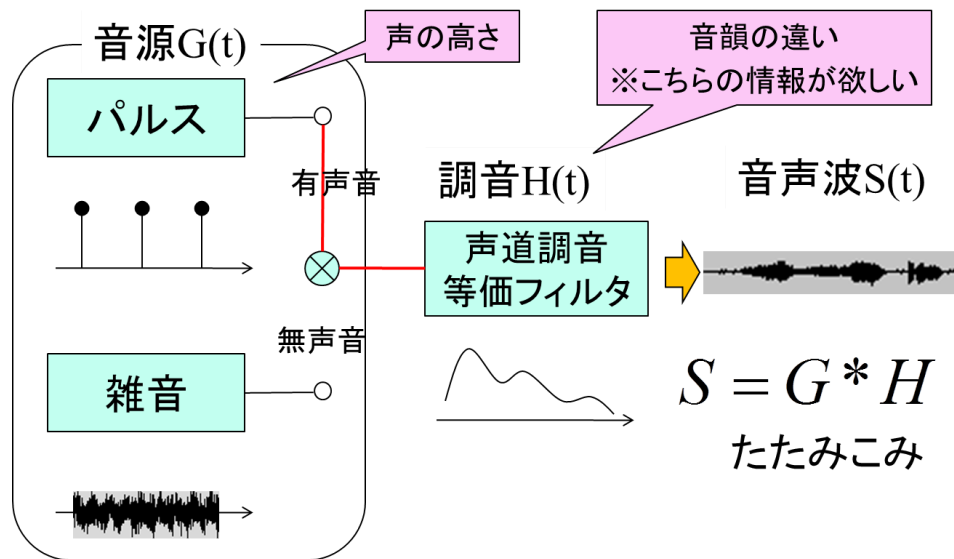
- 共振周波数はスペクトルのピークとして現れる



(b) 日本語母音識別のための特徴空間 (男声)

3.1.1 音声の場合 (4/6)

- 音声生成過程のモデル

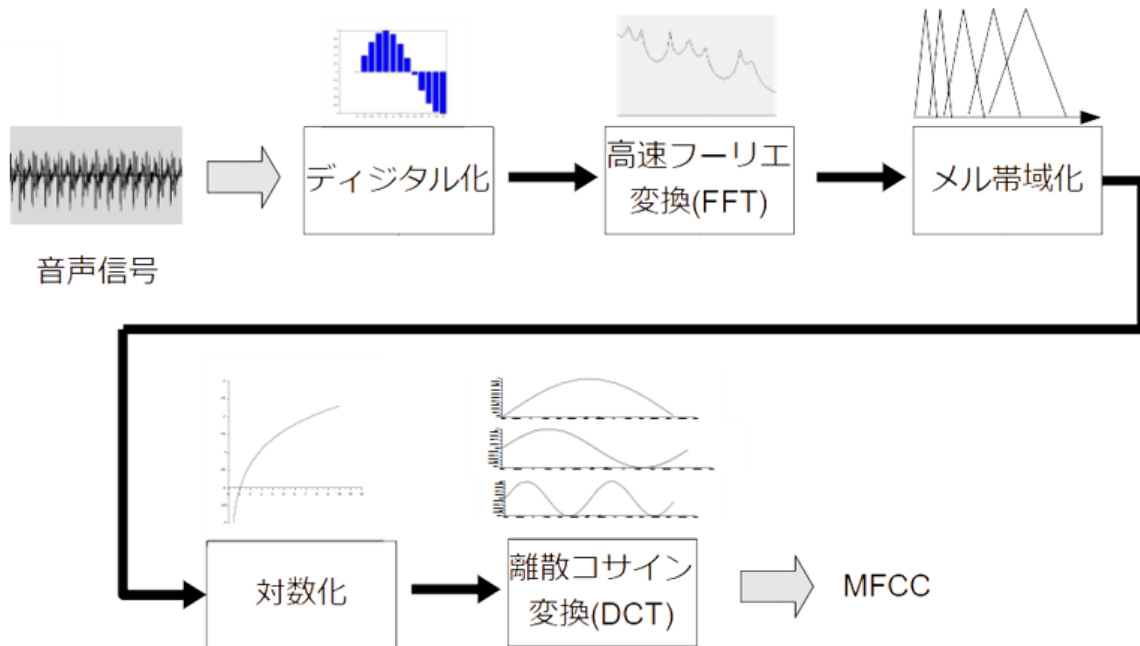


3.1.1 音声の場合 (5/6)

- 調音フィルタ特性 H (スペクトル包絡)の取り出し
 - 音声信号 $S = G * H$
 - ↓ フーリエ変換
 - スペクトル $S = G \cdot H$
 - ↓ 絶対値・メルフィルタ・対数化(人間の聴覚特性を反映)
 - 対数スペクトル $\log |S|^2 = \log |G|^2 + \log |H|^2$
 - ↓ 離散コサイン変換
 - ケプストラム $DCT \log |S|^2 = DCT \log |G|^2 + DCT \log |H|^2$
 - 音のスペクトルを信号とみなして周波数分析したもの
 - 音源 G (スペクトルの調波構造)の成分が高周波域、調音フィルタ H の成分が低周波域に現れる


3.1.1 音声の場合 (6/6)

- MFCC (Mel Frequency Cepstrum Coefficient)
 - 離散コサイン変換結果の低次(12次まで)の係数をスペクトル包絡の情報とみなす



3.1.2 画像の場合 (1/2)

- 画像の変動
 - 明るさの変化, 拡大・縮小, 回転など
- SIFT特徴量
 - 2枚の画像の対応抽出などに有効



3.1.2 画像の場合 (2/2)

- Bag of Visual Words


- SIFT特徴量の似ているベクトルを単語と見なし、出現頻度を特徴として識別問題に適用




⋮



学習画像セット



SIFT特徴量



Visual words抽出

(補足)自然言語処理の場合

- Bag of Words
 - 応用:文書分類
 - 例)商品レビューを 肯定的/否定的 に分類する
 - 文書を単語の多重集合(bag)とみなす
 - 文例)「顔認証はヤバいぐらい便利」
 - 形態素解析「顔認証 は ヤバい ぐらい 便利」



単語の種類数 = 次元数

(0, ..., 0, 1, 0, ..., 1, 0, 1, ...)

顔認証



ヤバい 便利

Positive

分類ラベル

3.2 特徴のスケールを揃える (1/2)

- 各軸で値のスケールが異なる場合
 - 値の標準化が必要



3.2 特徴のスケールを揃える (2/2)

- スケールの揃え方
 - 特徴空間の単位超立方体の体積を軸伸縮の前後で一定に保ち、かつパターン相互の距離を最小化 → 各軸の分散を等しくする
- 平均値を0にしておく
 - 学習における初期値の調整が不要
- 標準化の式(平均0、分散1への変換)

$$x'_i = \frac{x_i - m}{\sigma} \quad m : \text{平均}, \sigma : \text{標準偏差}$$

3.3 特徴は多いほどよいか

3.3.1 偶然に見つかってはまずい (1/4)

(1) 偶然の傾向とは

- 特徴は多いほどよいか
 - 特徴が多く、データ数が少ないと、偶然の傾向が現れるかもしれない
 - 特徴の次元数が高いほど、偶然の傾向が発見される可能性が高い

3.3.1 偶然に見つかってしまっはまずい (2/4)

(2) 学習に必要なパターン数

- 超平面の容量 $2(d + 1)$
 - $p(n, d)$: d 次元空間上で、適当に配置された n 個のパターンを任意に2クラスに分けたとき、超平面により線形分離できる確率

$$n < 2(d + 1) \Rightarrow p(n, d) \sim 1$$

$$n = 2(d + 1) \Rightarrow p(n, d) = 1/2$$

$$n > 2(d + 1) \Rightarrow p(n, d) \sim 0$$

3.3.1 偶然に見つかってしまっはまずい (3/4)

- 例題3.3

- データ数: 4、次元数: 1 $\Rightarrow p(4, 1) = 1/2$

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(a) データの配置

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(b) 二つに分離可能



3.3.1 偶然に見つかってしまっはまずい (4/4)

(3) 見つかるはずのないものが見つかった？

- $n \gg 2(d+1)$ のとき
 - もし、この条件で識別面が見つかったとしたら
 - 偶然には存在しえないものが見つかった
 - その識別面は必然的に存在していた

3.3.2 特徴を減らそう (1/2)

- (1) 力業で次元を減らす → 全ての組み合わせを評価する
- (2) スマートに主成分分析




(補足)共分散行列とは (1/2)

- データの広がりを調べる → 共分散行列
- 1次元の場合
 - 平均 $m = \frac{1}{N} \sum_{x \in \chi} x$
 - 分散 $\sigma^2 = \frac{1}{N} \sum_{x \in \chi} (x - m)^2$
- 多次元の場合
 - 平均ベクトル $\mathbf{m} = \frac{1}{N} \sum_{\mathbf{x} \in \chi} \mathbf{x}$
 - 共分散行列 $\Sigma = \frac{1}{N} \sum_{\mathbf{x} \in \chi} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T$

(補足)共分散行列とは (2/2)

- 各軸の平均・分散が等しいデータを区別できる



$$\Sigma = \begin{pmatrix} x\text{の分散} & x\text{と}y\text{の相関} \\ x\text{と}y\text{の相関} & y\text{の分散} \end{pmatrix}$$

3.3.2 特徴を減らそう (2/2)

- 主成分分析 (principal component analysis; PCA)
 - 主成分とは
 - データの分散が最大となる方向
 - PCA のアイディア
 - 主成分を分散の大きい順に少数抽出することで、データを少ない次元に投影(変換)する
 - PCA の手順
 1. データの標準化 $X_{std} = (X - m)/\sigma$
 2. 共分散行列の計算 $C = \frac{1}{N} X_{std}^T X_{std}$
 3. 共分散行列の固有値と固有ベクトルの計算 $Cv = \lambda v$ λ : 固有値, v : 対応する固有ベクトル
 4. 固有値の大きい順に固有ベクトル(主成分)を並べ替える $v_{sorted} = \text{sort}(v, \text{by} = \lambda)$
 5. データを主成分の空間に変換(投影)する $X_{pca} = X_{std} \cdot v_{sorted}[:, \tilde{d}]$

まとめ

- 特徴抽出部の役割
 - 特徴量の計算
 - 入力の種類および認識対象によって処理が異なる
 - 特徴の標準化
 - スケールの異なる特徴の識別に対する効果を公平にする
 - 特徴の選択
 - 実験的に有効な特徴を調べる
 - 低次元に変換する
- Jupyter notebook